

Programmierung für statistische Datenanalyse - Übungsblatt 3

Prof. Dr. Benjamin Buchwitz, André Münzberg

2026-07-04

Hinweis: Dem Argument FUN innerhalb der `*apply()`-Funktionen können auch anonyme Funktionen (FUN = `function(...){...}`) übergeben werden.

Aufgabe 1 (32 P)

Es wurde eine Liste namens `house`, die Informationen über ein Haus enthält, erstellt. Es sind folgende Ausgaben bekannt:

```
str(house)

## List of 7
## $ rooms          : chr [1:9] "kitchen" "bathroom1" "bathroom2" "bedroom1" ...
## $ squaremetre     : chr [1:9] "15" "10" "5" "12" ...
## $ site_squaremetre: num 300
## $                 : num [1:9, 1:3] 0 0 0 1 0 1 0 0 0 1 ...
## ..- attr(*, "dimnames")=List of 2
## .. ..$ : chr [1:9] "kitchen" "bathroom1" "bathroom2" "bedroom1" ...
## .. ..$ : chr [1:3] "balcony" "terrace" "number_windows"
## $ garden          : logi TRUE
## $ cellar          : logi FALSE
## $ kitchen         :List of 2
## ..$ fitted_kitchen : chr "available"
## ..$ electrical_appliance: num 2018
```

```
house

## $rooms
## [1] "kitchen"      "bathroom1"    "bathroom2"    "bedroom1"     "bedroom2"
## [6] "bedroom3"     "study"        "living_room"  "utility_room"
##
## $squaremetre
## [1] "15" "10" "5"  "12" "13" "14" "9"  "25" "10"
##
## $site_squaremetre
## [1] 300
##
## [[4]]
##           balcony terrace number_windows
## kitchen          0         1             2
## bathroom1        0         0             2
## bathroom2        0         0             1
```

```
## bedroom1      1      0      2
## bedroom2      0      0      1
## bedroom3      1      0      2
## study         0      0      1
## living_room   0      1      4
## utility_room  0      1      2
##
## $garden
## [1] TRUE
##
## $cellar
## [1] FALSE
##
## $kitchen
## $kitchen$fitted_kitchen
## [1] "available"
##
## $kitchen$electrical_appliance
## [1] 2018
```

- a) Erzeugen Sie die entsprechende Liste. Folgenden Code können Sie hierfür nutzen. Achten Sie auf die Datentypen und die Namensgebung!

```
listenelement_1 <- c("kitchen", "bathroom1", "bathroom2", "bedroom1", "bedroom2",
                     "bedroom3", "study", "living_room", "utility_room")
listenelement_2 <- c("15", "10", "5", "12", "13", "14", "9", "25", "10")
listenelement_4 <- c(0, 1, 2, 0, 0, 2, 0, 0, 1, 1, 0, 2, 0, 0, 1, 1, 0, 2, 0, 0, 1,
                     0, 1, 4, 0, 1, 2)
```

- b) Wie groß ist das Schlafzimmer 2 ("bedroom2") (in m^2)? Beantworten Sie diese Frage mithilfe einer *geeigneten* Abfragemöglichkeit in R.
- c) Benennen Sie das 4. Listenelement von **house** in **entrance** um (*entrance* ist hier im Sinne von Zugang bzw. Zutritt gemeint).
- d) Nutzen Sie **entrance** und bearbeiten Sie mithilfe *geeigneter* Funktionen des R-Pakets **dplyr** und des Pipe-Operators (Wickham et al. 2022) folgende Teilaufgaben.
- d.1) Wie viele Räume verfügen jeweils über zwei Fenster und haben einen Zugang zur Terrasse?
- d.2) Wie viele Räume verfügen jeweils über zwei oder mehr Fenster und haben keinen Zugang zur Terrasse?
- d.3) Wie viele Räume verfügen jeweils über mindestens ein Fenster und haben entweder einen Zugang zur Terrasse oder zum Balkon?
- d.4) Wie viele Räume existieren - in Abhängigkeit von der Anzahl an Fenstern -, die einen Zugang zum Balkon oder zur Terrasse besitzen?

Aufgabe 2 (39 P)

Gegeben ist folgender Data Frame namens `best_running_results`, der die Ergebnisse der besten 17 10km-Läufer:innen eines Laufwettkampfs enthält (siehe auch Tabelle 1).

Dabei beschreiben

- `runnerName` den Name (abgekürzt) der Läuferin bzw. des Läufers,
- `time` die gelaufene Zeit (Laufzeit) in Minuten,
- `man` und `woman`, ob die laufende Person als männlich oder weiblich registriert ist, und
- `achievement` die Leistungskategorie, in die der Läufer oder die Läuferin aufgrund seiner/ihrer Laufzeit eingeordnet wird.

```
best_running_results <- data.frame(runnerName = c("A.B.", "A.D.", "B.E.", "B.Z.", "C.E.",
                                                "G.L.", "G.S.", "M.E.", "M.M.", "M.N.",
                                                "S.S.", "S.L.", "T.A.", "T.Al.", "T.R.",
                                                "U.B.", "V.U."),
                                   time = c(41.20, 46.18, 44.20, 43.45, 46.42, 48.45, 51.13,
                                             41.54, 54.44, 56.44, 57.01, 47.56, 51.15, 49.32,
                                             48.12, 50.49, 51.20),
                                   man = c(1, 0, 1, 1, 0, 0, 1, 1, 0, 0, 0, 1, 0, 1, 1, 0, 1),
                                   woman = c(0, 1, 0, 0, 1, 1, 0, 0, 1, 1, 1, 0, 1, 0, 0, 1, 0),
                                   achievement = c("A", "C", "B", "B", "C", "D", "E", "A", "E",
                                                  "E", "E", "C", "E", "D", "D", "D", "E"))
```

Table 1: Laufergebnisse der besten 17 10km-Läufer:innen.

runnerName	time	man	woman	achievement
A.B.	41.20	1	0	A
A.D.	46.18	0	1	C
B.E.	44.20	1	0	B
B.Z.	43.45	1	0	B
C.E.	46.42	0	1	C
G.L.	48.45	0	1	D
G.S.	51.13	1	0	E
M.E.	41.54	1	0	A
M.M.	54.44	0	1	E
M.N.	56.44	0	1	E
S.S.	57.01	0	1	E
S.L.	47.56	1	0	C
T.A.	51.15	0	1	E
T.Al.	49.32	1	0	D
T.R.	48.12	1	0	D
U.B.	50.49	0	1	D
V.U.	51.20	1	0	E

Die Spalte `achievement` (Leistung) wurde nach folgender Übersicht erstellt:

achievement (Leistung)	time (Laufzeit)
A	≤ 42 min
B	> 42 min & ≤ 45 min
C	> 45 min & ≤ 48 min
D	> 48 min & ≤ 51 min
E	> 51 min

a) Basierend auf dem Datensatz `best_running_results`, geben Sie für jede der folgenden Aufgabenstellungen bzw. Abfragen zwei Umsetzungen an:

- Eine davon basiert **nicht** auf den Funktionen des `dplyr`-Pakets (Wickham et al. 2022) (d.h. auch **ohne** Pipe-Operator); es soll sich um einen Einzeiler handeln.
- Im Gegensatz dazu wird die andere Abfrage **mittels** `dplyr` (Wickham et al. 2022) **und** dem Pipe-Operator erstellt.

Sind die von Ihnen erzeugten Ergebnisse identisch? Überprüfen Sie dies!

Siehe folgendes Beispiel:

Beispiel:

Aufgabe: Reduzieren Sie den Datensatz `best_running_results` auf die Spalten `runnerName` und `time`.

- Lösung **ohne** `dplyr` und **ohne** Pipe-Operator:

```
b1 <- best_running_results[,c("runnerName", "time")]
```

- Lösung basierend auf `dplyr` **und** Pipe-Operator:

```
b2 <- best_running_results %>%  
  select(runnerName, time)
```

```
identical(b1, b2)
```

```
## [1] TRUE
```

- a.1) Ermitteln Sie, wie oft die einzelnen Leistungskategorien erzielt wurden.
- a.2) Geben Sie jeweils die Anzahl an Frauen vs. Männern an, die unter den 17 besten Läufer:innen vertreten sind.
- a.3) Sortieren Sie `best_running_results` nach aufsteigender Laufzeit.
- a.4) Geben Sie jeweils die Anzahl an Frauen und Männern an, die in die Leistungskategorie A bis D fallen.
- a.5) Geben Sie die Gesamtzahl an Läufer:innen an, die entweder der Leistungsgruppe A oder C angehören.
- b) Machen Sie sich mit der Funktion `split()` in base-R vertraut. Nutzen Sie diese, um `best_running_results` nach den fünf Leistungskategorien zu differenzieren. Benennen Sie das resultierende Objekt `running_achievements`. Welcher Klasse gehört `running_achievements` an?
- c) Beantworten Sie basierend auf `running_achievements` folgende Fragestellungen. Entscheiden Sie, ob Funktionen aus der Familie der `*apply()`-Funktionen und/oder des `dplyr`-Pakets (Wickham et al. 2022) notwendig sind. Wenn Sie Funktionen des `dplyr`-Pakets nutzen, verwenden Sie den Pipe-Operator.
- c.1) Wie viele Läufer:innen (Männer und Frauen zusammen) existieren in jeder, d.h. pro, Leistungskategorie? Der Rückgabewert ist ein Vektor.

- c.2) Wie viele Frauen und Männer existieren jeweils pro Leistungskategorie (Anzahl an Männern und Frauen pro Leistungskategorie getrennt)? Der Rückgabewert ist eine Matrix.
- c.3) Wie groß ist das arithmetische Mittel der Laufzeit für jede Leistungskategorie (pro Leistungskategorie wird kein Unterschied zwischen den Laufzeiten von Männern und Frauen getätigt)? Geben Sie die Werte in Form einer Liste aus.
- c.4) Wie groß ist der Median der Laufzeiten der Frauen, die der Leistungskategorie E angehören?
- d) Überschreiben Sie die Laufzeiten (Variable `time`) in `best_running_results`, indem Sie die Laufzeiten auf ganze Werte (keine Nachkommastellen) runden. Bestimmen Sie dann, wie viele unterschiedliche Laufzeiten existieren, wenn Sekunden bzw. Nachkommastellen keine Rolle spielen.

Aufgabe 3 (10 P)

- a) Welche Vorteile bieten `*apply()`-Funktionen, d.h., wann bietet es sich an, `*apply()`-Funktionen zu nutzen? Nennen Sie mindestens drei Vorteile und formulieren Sie pro genanntem Vorteil 1–2 Sätze.
- b) Ein häufig genannter Vorteil von `*apply()`-Funktionen beinhaltet Zeitersparnis. Überprüfen Sie dies anhand von Beispielen aus den vorherigen Aufgaben dieses Übungsblatts. *Hinweis:* R-Paket `microbenchmark` (Mersmann 2021)
- c) Wie können durch die Anwendung der Funktionen `lapply()` und `sapply()` auf eine Liste identische Rückgabewerte erzeugt werden?
Illustrieren Sie Ihren Lösungsweg anhand der folgenden Liste `l`, indem für jedes Listenelement (`a`, `b` und `c`) jeweils die Summe berechnet wird und formulieren Sie Ihre Schlussfolgerung in 1–2 Sätzen.

```
l <- list(a = c(10:2), b = c(1:5), c = c(0, 1, 0))
```

Aufgabe 4 (13 P)

Diese Aufgabe basiert auf dem `airquality`-Datensatz aus dem R-Paket `datasets` (R Core Team 2021). Machen Sie sich als Erstes mit dem Datensatz vertraut (siehe `?airquality`).

- a) Gegeben ist folgender Code, wobei die angewandten Funktionen hauptsächlich aus dem `dplyr`-Paket (Wickham et al. 2022) stammen:

```
air_filter <- filter(airquality, Month %in% c(7:9), Temp >= 80)
air_select <- select(air_filter, Solar.R, Wind, Temp, Month, Day)
air_mutate <- mutate(air_select, Temp_C = (Temp - 32)*(5/9))
air_arrange <- arrange(air_mutate, desc(Temp_C))
```

Beachten Sie dabei folgende Gleichung:

$$Celsius (^{\circ}C) = (^{\circ}F - 32)/1.8,$$

wobei es sich bei $^{\circ}F$ um Grad Fahrenheit handelt. (National Institute of Standards and Technology (NIST) 2021)

Schreiben Sie den Code um, indem Sie den Pipe-Operator nutzen, ohne die Zwischenschritte in separate Variablen zu schreiben. Benennen Sie das insgesamt Ergebnis `air_Temp_C`.

- b) Nachdem Sie den Code in a) *umgeschrieben* haben, beschreiben Sie, welche Werte `air_Temp_C` enthält und wie `air_Temp_C` erzeugt wurde. Achten Sie dabei darauf, die Variablen im Sachkontext zu gebrauchen.

- c) Nach Durchführung der Codezeilen 1–2 des in a) angegebenen Codes wird `air_select` erhalten:

```
head(air_select)
```

```
##   Solar.R Wind Temp Month Day
## 1    269  4.1   84     7    1
## 2    248  9.2   85     7    2
## 3    236  9.2   81     7    3
## 4    101 10.9   84     7    4
## 5    175  4.6   83     7    5
## 6    314 10.9   83     7    6
```

Wie kann der Aufruf der Funktion `select()` in der 2. Codezeile *verkürzt* werden, sodass der gleiche Rückgabewert für `air_select` erhalten wird? Beschreiben Sie dies kurz in eigenen Worten und setzen Sie dies um! *Hinweise:* Es ist **nicht** der Pipe-Operator gemeint! Inklusion vs. Exklusion.

- d) Was ist der Unterschied zwischen den Funktionen `dplyr::mutate()` und `dplyr::transmute()` hinsichtlich des erhaltenen Ergebnisses? Beschreiben Sie dies in eigenen Worten und wenden Sie `mutate()` und `transmute()` beispielhaft auf `air_Temp_C` an, um den Unterschied zu illustrieren.

Aufgabe 5 (5 P)

Beschreiben und erklären Sie in eigenen Worten, wie grundsätzlich Plots, die auf dem R-Paket `ggplot2` (Wickham 2016) basieren, erzeugt werden. Verwenden Sie dabei u.a. die Begriffe *Syntax* und *Semantik* und gehen Sie u.a. auf Geoms und Ästhetische Eigenschaften (*aesthetics*) ein.

Aufgabe 6 (50 P)

Für diese Aufgabe nutzen Sie vorwiegend die Funktionen der R-Pakete `dplyr` (Wickham et al. 2022) und `ggplot2` (Wickham 2016). Wenden Sie diese - wie im Folgenden beschrieben - auf den Datensatz `airquality` (R Core Team 2021) unter Verwendung des Pipe-Operators an:

- a) Filtern Sie alle Windgeschwindigkeiten, die mindestens 5 und höchstens 18 mph betragen. Weiterhin sind alle Variablen bis auf die Solarstrahlung und den Ozongehalt von Interesse. Anschließend ist der Datensatz um eine Spalte namens `Season` zu erweitern, in der die Jahreszeiten (“Spring” (März, April, Mai), “Summer” (Juni, Juli, August), “Autumn” (September, Oktober, November), “Winter” (Dezember, Januar, Februar)) der in der Spalte `Month` angegebenen Monate als Faktor gespeichert sind. Nennen Sie den resultierenden Datensatz `air_season`.
- b) Basierend auf den Ergebnissen aus a) erstellen Sie einen `ggplot`, der wie folgt aussieht:




c) Basierend auf den Ergebnissen aus a) erstellen Sie einen `ggplot`, der wie folgt aussieht:



d) Basierend auf den Ergebnissen aus a) erstellen Sie einen `ggplot`, der wie folgt aussieht:




e) Basierend auf den Ergebnissen aus a) erstellen Sie einen `ggplot`, der wie folgt aussieht:



- f) In den Aufgabenteilen c) und e) dieser Aufgabe 3 wird in den Legenden der Abbildungen eine kontinuierliche Farbskala für den Monat angegeben. Warum ist dies nicht korrekt? Wie müssten die Legenden jeweils aussehen und wie erreichen Sie dies? Setzen Sie dies beispielhaft für Aufgabenteil 3c) um.

g) Basierend auf den Ergebnissen aus a) erstellen Sie einen `ggplot`, der wie folgt aussieht (bei den in blau eingezeichneten Linien handelt es sich um lineare Regressionsgeraden):



h) Basierend auf dem (unmodifizierten) `airquality`-Datensatz (R Core Team 2021): Ermitteln Sie mithilfe eines `ggplots`, ob es bezüglich der Windgeschwindigkeit möglicherweise *Ausreißer* gibt. Schlagen Sie ein grafisches Mittel vor und erläutern Sie dessen Funktionsweise. Können Sie *Ausreißer* identifizieren? Wenn ja, um welche Werte handelt es sich?

i) Gegeben ist folgender Code:

```
median(airquality$Solar.R[which(airquality$Wind <= 19.1 & airquality$Month==6)])
median(airquality$Solar.R[which(airquality$Wind <= 19.1 & airquality$Month==7)])
median(airquality$Solar.R[which(airquality$Wind <= 19.1 & airquality$Month==9)])
```

i.1) Was wird mittels des in i) angegebenen Codes berechnet?

i.2) Schreiben Sie den Code in i) mittels *geeigneter* `dplyr`-Funktionen und des Pipe-Operators (Wickham et al. 2022) um, sodass die gleichen Ergebnisse, jedoch *tabellenartig*, erhalten werden. *Hinweis*: Als Rückgabewert empfiehlt sich ein `Tibble`.

Aufgabe 7 (10 P)

a) Erzeugen Sie basierend auf dem `airquality`-Datensatz (R Core Team 2021) in **base-R** (keine `ggplot2`-Funktionen) einen Plot,

- in dem der Zusammenhang der Windgeschwindigkeit von der Temperatur dargestellt ist,
- eine entsprechende Regressionsgerade mit y-Achsenabschnitt in blau eingezeichnet ist und
- die Achsen angemessen inklusive Einheiten beschriftet sind.

Welche Zwischenschritte - bezogen auf die Ermittlung und Einzeichnung einer Regressionsgeraden - sind hierfür notwendig?

- b) Schreiben Sie die Gleichung der Regressionsgeraden aus Aufgabenteil a) unter Verwendung der Variablennamen auf. Welche Informationen benötigen Sie hierfür und wie erhalten Sie diese? *Hinweis:* Verwenden Sie mathematische Notationen (L^AT_EX).

Aufgabe 8 (10 P)

Sie kennen bereits den folgenden Data Frame namens `best_running_results`, der die Ergebnisse der besten 17 10km-Läufer:innen eines Laufwettkampfs enthält (siehe auch Tabelle 1).

```
best_running_results <- data.frame(runnerName = c("A.B.", "A.D.", "B.E.", "B.Z.", "C.E.",
                                                "G.L.", "G.S.", "M.E.", "M.M.", "M.N.",
                                                "S.S.", "S.L.", "T.A.", "T.Al.", "T.R.",
                                                "U.B.", "V.U."),
                                   time = c(41.20, 46.18, 44.20, 43.45, 46.42, 48.45, 51.13,
                                           41.54, 54.44, 56.44, 57.01, 47.56, 51.15, 49.32,
                                           48.12, 50.49, 51.20),
                                   man = c(1, 0, 1, 1, 0, 0, 1, 1, 0, 0, 0, 1, 0, 1, 1, 0, 1),
                                   woman = c(0, 1, 0, 0, 1, 1, 0, 0, 1, 1, 1, 0, 1, 0, 0, 1, 0))
```

Table 2: Laufergebnisse der besten 17 10km-Läufer:innen.

runnerName	time	man	woman
A.B.	41.20	1	0
A.D.	46.18	0	1
B.E.	44.20	1	0
B.Z.	43.45	1	0
C.E.	46.42	0	1
G.L.	48.45	0	1
G.S.	51.13	1	0
M.E.	41.54	1	0
M.M.	54.44	0	1
M.N.	56.44	0	1
S.S.	57.01	0	1
S.L.	47.56	1	0
T.A.	51.15	0	1
T.Al.	49.32	1	0
T.R.	48.12	1	0
U.B.	50.49	0	1
V.U.	51.20	1	0


Der Datensatz `best_running_results` erhielt eine weitere Spalte namens `achievement` (Leistung), die nach folgender Übersicht erstellt wurde:

achievement (Leistung)	time (Laufzeit)
A	<= 42 min
B	> 42 min & <= 45 min
C	> 45 min & <= 48 min
D	> 48 min & <= 51 min

achievement (Leistung)	time (Laufzeit)
E	> 51 min

- Machen Sie sich mit der Funktion `dplyr::case_when()` (Wickham et al. 2022) vertraut. Nutzen Sie diese, um den Data Frame `best_running_results` um die Spalte `achievement` nach vorangegangener Übersicht zu erweitern.
- Erzeugen Sie den folgenden Plot. *Hinweis:* Modifizieren Sie den Datensatz `best_running_results`, bevor Sie den Plot erzeugen.

Boxplots der 17 schnellsten 10km–Laufzeiten nach Geschlecht



Quellenverzeichnis

- Mersmann, Olaf. 2021. *Microbenchmark: Accurate Timing Functions*. <https://CRAN.R-project.org/package=microbenchmark>.
- National Institute of Standards and Technology (NIST). 2021. *SI Units – Temperature*. USA, Gaithersburg. <https://www.nist.gov/pml/weights-and-measures/si-units-temperature>.
- R Core Team. 2021. *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing. <https://www.R-project.org/>.
- Wickham, Hadley. 2016. *Ggplot2: Elegant Graphics for Data Analysis*. Springer-Verlag New York. <https://ggplot2.tidyverse.org>.
- Wickham, Hadley, Romain François, Lionel Henry, and Kirill Müller. 2022. *Dplyr: A Grammar of Data Manipulation*. <https://CRAN.R-project.org/package=dplyr>.