

# Programmierung für statistische Datenanalyse - Übungsblatt 4

Prof. Dr. Benjamin Buchwitz

2026-08-09

## Aufgabe 1 (13 P)

Diese Aufgabe basiert auf dem `airquality`-Datensatz aus dem R-Paket `datasets` (R Core Team 2021). Machen Sie sich als Erstes mit dem Datensatz vertraut (siehe `?airquality`).

- a) Gegeben ist folgender Code, wobei die angewandten Funktionen hauptsächlich aus dem `dplyr`-Paket (Wickham et al. 2022) stammen:

```
1 air_filter <- filter(airquality, Month %in% c(7:9), Temp >= 80)
2 air_select <- select(air_filter, Solar.R, Wind, Temp, Month, Day)
3 air_mutate <- mutate(air_select, Temp_C = (Temp - 32)*(5/9))
4 air_arrange <- arrange(air_mutate, desc(Temp_C))
```

Beachten Sie dabei folgende Gleichung:

$$Celsius (^{\circ}C) = (^{\circ}F - 32)/1.8,$$

wobei es sich bei  $^{\circ}F$  um Grad Fahrenheit handelt. (National Institute of Standards and Technology (NIST) 2021)

Schreiben Sie den Code um, indem Sie den Pipe-Operator nutzen, ohne die Zwischenschritte in separate Variablen zu schreiben. Benennen Sie das insgesamt Ergebnis `air_Temp_C`.

- b) Nachdem Sie den Code in a) *umgeschrieben* haben, beschreiben Sie, welche Werte `air_Temp_C` enthält und wie `air_Temp_C` erzeugt wurde. Achten Sie dabei darauf, die Variablen im Sachkontext zu gebrauchen.
- c) Nach Durchführung der Codezeilen 1–2 des in a) angegebenen Codes wird `air_select` erhalten:

```
1 head(air_select)

##   Solar.R Wind Temp Month Day
## 1     269  4.1  84     7    1
## 2     248  9.2  85     7    2
## 3     236  9.2  81     7    3
## 4     101 10.9  84     7    4
## 5     175  4.6  83     7    5
## 6     314 10.9  83     7    6
```

Wie kann der Aufruf der Funktion `select()` in der 2. Codezeile *verkürzt* werden, sodass der gleiche Rückgabewert für `air_select` erhalten wird? Beschreiben Sie dies kurz in eigenen Worten und setzen Sie dies um! *Hinweise:* Es ist **nicht** der Pipe-Operator gemeint! Inklusion vs. Exklusion.

- d) Was ist der Unterschied zwischen den Funktionen `dplyr::mutate()` und `dplyr::transmute()` hinsichtlich des erhaltenen Ergebnisses? Beschreiben Sie dies in eigenen Worten und wenden Sie `mutate()` und `transmute()` beispielhaft auf `air_Temp_C` an, um den Unterschied zu illustrieren.

## Aufgabe 2 (5 P)

Beschreiben und erklären Sie in eigenen Worten, wie grundsätzlich Plots, die auf dem R-Paket `ggplot2` (Wickham 2016) basieren, erzeugt werden. Verwenden Sie dabei u.a. die Begriffe *Syntax* und *Semantik* und gehen Sie u.a. auf Geoms und Ästhetische Eigenschaften (*aesthetics*) ein.

## Aufgabe 3 (50 P)

Für diese Aufgabe nutzen Sie vorwiegend die Funktionen der R-Pakete `dplyr` (Wickham et al. 2022) und `ggplot2` (Wickham 2016). Wenden Sie diese - wie im Folgenden beschrieben - auf den Datensatz `airquality` (R Core Team 2021) unter Verwendung des Pipe-Operators an:

- Filtern Sie alle Windgeschwindigkeiten, die mindestens 5 und höchstens 18 mph betragen. Weiterhin sind alle Variablen bis auf die Solarstrahlung und den Ozongehalt von Interesse. Anschließend ist der Datensatz um eine Spalte namens `Season` zu erweitern, in der die Jahreszeiten ("Spring" (März, April, Mai), "Summer" (Juni, Juli, August), "Autumn" (September, Oktober, November), "Winter" (Dezember, Januar, Februar)) der in der Spalte `Month` angegebenen Monate als Faktor gespeichert sind. Nennen Sie den resultierenden Datensatz `air_season`.
- Basierend auf den Ergebnissen aus a) erstellen Sie einen `ggplot`, der wie folgt aussieht:



c) Basierend auf den Ergebnissen aus a) erstellen Sie einen `ggplot`, der wie folgt aussieht:



d) Basierend auf den Ergebnissen aus a) erstellen Sie einen `ggplot`, der wie folgt aussieht:



e) Basierend auf den Ergebnissen aus a) erstellen Sie einen `ggplot`, der wie folgt aussieht:



- f) In den Aufgabenteilen c) und e) dieser Aufgabe 3 wird in den Legenden der Abbildungen eine kontinuierliche Farbskala für den Monat angegeben. Warum ist dies nicht korrekt? Wie müssten die Legenden jeweils aussehen und wie erreichen Sie dies? Setzen Sie dies beispielhaft für Aufgabenteil 3c) um.

g) Basierend auf den Ergebnissen aus a) erstellen Sie einen `ggplot`, der wie folgt aussieht (bei den in blau eingezeichneten Linien handelt es sich um lineare Regressionsgeraden):



h) Basierend auf dem (unmodifizierten) `airquality`-Datensatz (R Core Team 2021): Ermitteln Sie mithilfe eines `ggplots`, ob es bezüglich der Windgeschwindigkeit möglicherweise *Ausreißer* gibt. Schlagen Sie ein grafisches Mittel vor und erläutern Sie dessen Funktionsweise. Können Sie *Ausreißer* identifizieren? Wenn ja, um welche Werte handelt es sich?

i) Gegeben ist folgender Code:

```
1 median(airquality$Solar.R[which(airquality$Wind <= 19.1 & airquality$Month==6)])
2
3 median(airquality$Solar.R[which(airquality$Wind <= 19.1 & airquality$Month==7)])
4
5 median(airquality$Solar.R[which(airquality$Wind <= 19.1 & airquality$Month==9)])
```

i.1) Was wird mittels des in i) angegebenen Codes berechnet?

i.2) Schreiben Sie den Code in i) mittels *geeigneter* `dplyr`-Funktionen und des Pipe-Operators (Wickham et al. 2022) um, sodass die gleichen Ergebnisse, jedoch *tabellenartig*, erhalten werden. *Hinweis*: Als Rückgabewert empfiehlt sich ein `Tibble`.

## Aufgabe 4 (10 P)

- a) Erzeugen Sie basierend auf dem **airquality**-Datensatz (R Core Team 2021) in **base-R** (**keine ggplot2-Funktionen**) einen Plot,
- in dem der Zusammenhang der Windgeschwindigkeit von der Temperatur dargestellt ist,
  - eine entsprechende Regressionsgerade mit y-Achsenabschnitt in blau eingezeichnet ist und
  - die Achsen angemessen inklusive Einheiten beschriftet sind.

Welche Zwischenschritte - bezogen auf die Ermittlung und Einzeichnung einer Regressionsgeraden - sind hierfür notwendig?

- b) Schreiben Sie die Gleichung der Regressionsgeraden aus Aufgabenteil a) unter Verwendung der Variablennamen auf. Welche Informationen benötigen Sie hierfür und wie erhalten Sie diese? *Hinweis:* Verwenden Sie mathematische Notationen (L<sup>A</sup>T<sub>E</sub>X).

## Aufgabe 5 (12 P)

Vom Übungsblatt 3 kennen Sie bereits den folgenden Data Frame namens `best_running_results`, der die Ergebnisse der besten 17 10km-Läufer:innen eines Laufwettkampfs enthält (siehe auch Tabelle 1).

```
1 best_running_results <- data.frame(runnerName = c("A.B.", "A.D.", "B.E.", "B.Z.", "C.E.",
2                                           "G.L.", "G.S.", "M.E.", "M.M.", "M.N.",
3                                           "S.S.", "S.L.", "T.A.", "T.Al.", "T.R.",
4                                           "U.B.", "V.U."),
5                               "time" = c(41.20, 46.18, 44.20, 43.45, 46.42, 48.45, 51.13,
6                                           41.54, 54.44, 56.44, 57.01, 47.56, 51.15, 49.32,
7                                           48.12, 50.49, 51.20),
8                               "man" = c(1, 0, 1, 1, 0, 0, 1, 1, 0, 0, 0, 1, 0, 1, 1, 0, 1),
9                               "woman" = c(0, 1, 0, 0, 1, 1, 0, 0, 1, 1, 1, 0, 1, 0, 0, 1, 0))
```

Table 1: Laufergebnisse der besten 17 10km-Läufer:innen.

| runnerName | time  | man | woman |
|------------|-------|-----|-------|
| A.B.       | 41.20 | 1   | 0     |
| A.D.       | 46.18 | 0   | 1     |
| B.E.       | 44.20 | 1   | 0     |
| B.Z.       | 43.45 | 1   | 0     |
| C.E.       | 46.42 | 0   | 1     |
| G.L.       | 48.45 | 0   | 1     |
| G.S.       | 51.13 | 1   | 0     |
| M.E.       | 41.54 | 1   | 0     |
| M.M.       | 54.44 | 0   | 1     |
| M.N.       | 56.44 | 0   | 1     |
| S.S.       | 57.01 | 0   | 1     |
| S.L.       | 47.56 | 1   | 0     |
| T.A.       | 51.15 | 0   | 1     |
| T.Al.      | 49.32 | 1   | 0     |
| T.R.       | 48.12 | 1   | 0     |
| U.B.       | 50.49 | 0   | 1     |
| V.U.       | 51.20 | 1   | 0     |

Auf dem Übungsblatt 3 enthielt `best_running_results` eine weitere Spalte namens `achievement` (Leistung), die nach folgender Übersicht erstellt wurde:

| achievement (Leistung) | time (Laufzeit)            |
|------------------------|----------------------------|
| A                      | $\leq 42$ min              |
| B                      | $> 42$ min & $\leq 45$ min |
| C                      | $> 45$ min & $\leq 48$ min |
| D                      | $> 48$ min & $\leq 51$ min |
| E                      | $> 51$ min                 |

- Machen Sie sich mit der Funktion `dplyr::case_when()` (Wickham et al. 2022) vertraut. Nutzen Sie diese, um den Data Frame `best_running_results` um die Spalte `achievement` nach vorangegangener Übersicht zu erweitern.
- Erzeugen Sie den folgenden Plot. *Hinweis:* Modifizieren Sie den Datensatz `best_running_results`, bevor Sie den Plot erzeugen.

Boxplots der 17 schnellsten 10km-Laufzeiten nach Geschlecht





## Quellenverzeichnis

National Institute of Standards and Technology (NIST). 2021. *SI Units – Temperature*. USA, Gaithersburg. <https://www.nist.gov/pml/weights-and-measures/si-units-temperature>.

R Core Team. 2021. *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing. <https://www.R-project.org/>.

Wickham, Hadley. 2016. *Ggplot2: Elegant Graphics for Data Analysis*. Springer-Verlag New York. <https://ggplot2.tidyverse.org>.

Wickham, Hadley, Romain François, Lionel Henry, and Kirill Müller. 2022. *Dplyr: A Grammar of Data Manipulation*. <https://CRAN.R-project.org/package=dplyr>.